



Tecnologia incorporando inteligência artificial para triagem emergencial e personalização de atendimento hospitalar com base em indicadores de risco do paciente.

Pedro Vinicius Mastandrea Santos - RA 10389910

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Programa de graduação em Sistemas de Informação – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10389910@mackenzista.com.br

Resumo. Este projeto aborda a aplicação de tecnologias de inteligência artificial (IA) e Aprendizado de Máquina no contexto da medicina moderna, com foco na otimização do atendimento hospitalar emergencial. O trabalho propõe a implementação de um sistema de apoio à decisão clínica, utilizando algoritmo de Árvores de Decisão (DT), para aprimorar o processo de triagem de pacientes em pronto-socorros com base no Protocolo de Manchester. O objetivo principal é utilizar bibliotecas como o Pandas para análise de dados e Scikit-learn para Machine Learning, treinado com dados clínicos para classificar o nível de risco e prioridade de atendimento de forma automatizada e mais precisa possível. A metodologia inclui a análise exploratória dos dados, o treinamento do modelo e a avaliação de sua performance. Espera-se, como resultado, um modelo preciso de classificação desses dados, bem como uma reflexão sobre os desafios éticos e práticos da implementação, como a privacidade dos dados e a necessidade de validação clínica rigorosa.

Palavras-chave: medicina; inteligência artificial; aprendizado de máquina; triagem de emergência; Protocolo de Manchester; sistema de apoio à decisão; medicina de emergência.

Abstract. This project addresses the application of artificial intelligence (AI) and Machine Learning technologies in the context of modern medicine, with a focus on optimizing emergency hospital care. The work proposes the implementation of a clinical decision support system, using a Decision Tree (DT) algorithm, to enhance the patient triage process in emergency departments based on the Manchester Triage System. The main objective is to use libraries such as Pandas for data analysis and Scikit-learn for Machine Learning, trained with clinical data to classify the level of risk and care priority in an automated and highly accurate manner. The adopted methodology includes exploratory data analysis, model training, and performance evaluation. The expected result is an accurate model for classifying this data, as well as a reflection on the ethical and practical challenges of implementation, such as data privacy and the need for rigorous clinical validation.

Keywords: *medicine; artificial intelligence; machine learning; emergency triage; Manchester Triage System; clinical decision support system; emergency medicine.*

1. Introdução

A. Contextualização: A aplicação de tecnologias como Inteligência Artificial (IA) e Aprendizado de Máquina (ML) tem se mostrado cada vez mais impactante na medicina moderna. Através da análise de grandes volumes de dados clínicos, essas ferramentas vêm aprimorando a precisão de diagnósticos, a previsão de prognósticos e a personalização de tratamentos, movimento que é potencializado pelo avanço da telemedicina para expandir o acesso a sistemas de saúde de alta qualidade.

B. Justificativa: Em um contexto hospitalar, a triagem de emergência é um processo crítico, e o Protocolo de Manchester (Manchester Triage System), embora seja o padrão, possui limitações como a subjetividade, a dependência da experiência do profissional e os custos com treinamento. Diante desses desafios, a aplicação de algoritmos de IA surge como uma solução para aprimorar a precisão do processo, reduzir filas de esperas (um problema chave no setor de saúde pública brasileiro) e até otimizar a alocação de recursos.

C. Objetivo: O objetivo central deste trabalho é construir e avaliar um protótipo de sistema de classificação de risco em Python. O sistema utilizará as bibliotecas Pandas para manipulação de dados e Scikit-learn para a implementação de um algoritmo de Árvore de Decisão, sendo treinado com dados de atendimento emergencial para auxiliar na triagem de pacientes, seguindo sempre a lógica do Protocolo de Manchester.

D. Opção do projeto: Este projeto se enquadra na Opção Framework, pois emprega a ferramenta de Machine Learning Scikit-learn para solucionar um problema de classificação no contexto da triagem emergencial.

2. Descrição do problema

Atualmente o processo de triagem em unidades de pronto-atendimento, embora padronizado pelo Protocolo de Manchester, enfrenta desafios que impactam a eficiência de operação e também a segurança do paciente. As limitações incluem a variabilidade na classificação de casos intermediários ou pouco específicos, a forte dependência da experiência do profissional e a sobrecarga em ambientes de alto fluxo. Tais falhas podem levar a classificações de risco imprecisas, resultando no aumento do tempo de espera e na alocação ineficiente de recursos, o que representa problemas críticos para o atendimento emergencial de saúde, especialmente no setor público brasileiro por exemplo.

3. Aspectos Éticos do uso da IA

A implementação de IA na triagem emergencial envolve responsabilidades éticas cruciais. A literatura alerta para a necessidade de uma regulamentação clara que garanta a privacidade dos dados (anonimidade) e a qualidade do cuidado (ANISHCHENKO et al., 2023). Outros desafios incluem os altos custos de desenvolvimento, que podem limitar o acesso (GORDO-VIDAL; GORDO-HERRERA, 2025), e o risco de decisões médicas erradas potencializado por dados imprecisos ou ferramentas de confiabilidade questionável (GUTIÉRREZ-CIRLOS et al., 2023). É fundamental que o sistema seja uma ferramenta de apoio, com a decisão final permanecendo com o profissional de saúde, e que seja baseado em dados confiáveis e auditáveis para evitar vieses e garantir uma aplicação segura a todos.

4. Dataset e Análise exploratória

4.1 Dataset

O dataset escolhido por mim foi "Emergency Service - Triage Application" ([Emergency Service - Triage Application](#)) um estudo baseado em registros de atendimento de 1267 adultos em dois sistemas de atendimento emergenciais entre outubro de 2016 e setembro de 2017. Nele contém diversas variáveis importantes para o processo de triagem emergencial, que podem ser utilizados para realizar o treinamento do modelo proposto, como sinais vitais, dados demográficos, sintomas/queixas, nível de dor, e a variável-alvo: O nível de triagem atribuído por um especialista KTAS_expert, que servirá como a nossa variável a ser prevista pelo modelo.

4.2 Análise exploratória dos dados/ Preparação dos dados

Para a limpeza e normalização dos dados foi realizado:

- Remoção linhas com valores ausentes na coluna 'Diagnosis in ED'
- Remoção da coluna 'Saturation' por ter muitos valores ausentes
- Conversão colunas numericas, tratando erros e separador decimal
- Limitado os outliers na coluna 'Length of stay_min' (em 95%)
- Filtrado os dados onde KTAS_expert não é nulo para análises de triagem

Na análise exploratória as seguintes relações foram feitas:

- Gênero vs. Nível de Triagem: Esta análise explorou a distribuição da população por gênero em cada nível de triagem. A visualização mostrou a contagem de pacientes masculinos e femininos, fornecendo uma visão demográfica da triagem sem indicar uma relação direta entre esses indicadores.
- Idade vs. Nível de Triagem: Por meio de gráficos de faixas etárias e um box-plot, a análise indicou que pacientes mais velhos tendem a ser classificados em níveis de triagem mais urgentes, uma relação esperada devido à maior fragilidade de saúde nesse grupo.
- Diagnóstico vs. Nível de Triagem: Esta análise já demonstrou uma forte correlação. Os gráficos de barras empilhadas identificaram que certos diagnósticos estão consistentemente associados a níveis de triagem de maior ou menor urgência, refletindo a gravidade inerente das condições.
- Sintoma (Queixa Principal) vs. Nível de Triagem: Similar ao diagnóstico, a queixa principal é um dos indicadores mais fortes. Os gráficos revelaram quais sintomas são mais prevalentes em cada nível de triagem, sendo um dado crucial para a decisão inicial.
- Nível de Dor vs. Nível de Triagem: A análise por box-plot mostrou a distribuição do nível de dor em cada triagem. Embora a dor seja um fator importante, ela não é o único, e um paciente com alto nível de dor não necessariamente é triado com o nível máximo de urgência

Na seção de preparação dos dados foram estruturados as informações para o treinamento do modelo:

- Transformação de variáveis categóricas - Por se tratar do algoritmo de Árvore de Decisão, trabalhar com dados numéricos é mais eficiente e preciso, então foi aplicado a técnica de One-Hot Encoding, utilizando a função pd.get_dummies do Pandas. Isso foi feito para a Chief_complain (queixa principal) e também para Diagnosis in ED (diagnóstico no pronto-socorro). Essa abordagem garante que o modelo não atribui uma importância artificial a uma queixa ou diagnóstico apenas por sua ordem alfabética.

- Atributos de entrada - Atributos com informações clínicas essenciais tais como: Chief_complain, Age, Sex, NRS_pain, SBP, DBP, HR, RR e BT.
- Atributos de saída - Foco em duas variáveis cruciais: Diagnosis in ED (diagnóstico no pronto-socorro) e o KTAS_expert (o nível de triagem atribuído por especialista). A ideia é que o modelo seja capaz de prever a provável causa do atendimento, e relacionar com sua urgência na triagem emergencial.

5. Metodologia e resultados esperados

Metodologia: A abordagem combina uma pesquisa exploratória e qualitativa com o desenvolvimento de um protótipo em python. Foi utilizado um dataset de acesso aberto com dados de atendimento emergencial, que foi preparado e analisado com a biblioteca Pandas. Em seguida, utilizando a biblioteca Scikit-learn, um modelo de classificação baseado no algoritmo de Árvore de Decisão, será treinado e avaliado com um conjunto de dados de teste medindo sua performance através de métricas de acurácia, matriz de confusão e relatórios de classificação (Recall, Precision e F1-Score)

Resultados Esperados: Espera-se obter um modelo funcional capaz de classificar a urgência do paciente com alta acurácia, otimizando o fluxo de atendimento e reduzindo o tempo de espera.

Link github do projeto: [pmastn/ProjetoIATriagemEmergencial](https://github.com/pmastn/ProjetoIATriagemEmergencial)

5. Referências

OWJI, L. et al. An open-access dataset of emergency department admissions at a large teaching hospital in Iran. *Scientific Data*, v. 8, n. 1, p. 278, out. 2021. Disponível em: <https://doi.org/10.1016/j.dib.2024.110827>. Acesso em: 22 set. 2025.

ANISHCHENKO, M. A. et al. Inteligência artificial em medicina: aspectos legais, éticos e sociais. *Acta Bioethica*, Santiago, v. 29, n. 1, p. 63-72, 2023. Disponível em: <https://doi.org/10.4067/S1726-569X2023000100063>. Acesso em: 22 set. 2025.

CHATTOPADHYAY, S. Decoding Medical Diagnosis with Machine Learning Classifiers. *Medinformatics*, BON VIEW PUBLISHING, p. 1-8, abr. 2024. Disponível em: <https://doi.org/10.47852/bonviewMEDIN42022583>. Acesso em: 22 set. 2025.

GORDO-VIDAL, F.; GORDO-HERRERA, N. Artificial intelligence and machine learning systems: fascination vs reality. *Emergencias*, v. 37, n. 1, p. 3-4, 2025.

Disponível em:
<https://revistaemergencias.org/wp-content/uploads/2024/12/003-004.pdf>. Acesso em: 22 set. 2025.

GUTIÉRREZ-CIRLOS, C. et al. ChatGPT: oportunidades y riesgos en la asistencia, docencia e investigación médica. Gaceta Médica de México, v. 159, n. 5, p. 382-389, 2023. Disponível em: <https://doi.org/10.24875/GMM.23000155>. Acesso em: 22 set. 2025.

KE, E. et al. Machine learning methods applied to triage in emergency services: A systematic review. International Journal of Medical Informatics, Elsevier, v. 177, p. 105153, set. 2023. Disponível em: <https://doi.org/10.1016/j.ijmedinf.2023.105153>. Acesso em: 22 set. 2025.

LANZAGORTA-ORTEGA, D.; CARRILLO-PÉREZ, D. L.; CARRILLO-ESPER, R. Inteligência artificial em medicina: presente e futuro. Gaceta Médica de México, v. 158, n. S1, p. 17-21, 2022. Disponível em: https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0016-38132022001100017. Acesso em: 22 set. 2025.

LINDNER, G.; RAVIOLI, S. Performance of the artificial intelligence-based Swiss medical assessment system versus Manchester triage system in the emergency department: A retrospective analysis. American Journal of Emergency Medicine, v. 94, p. 46-49, 2025. Disponível em: <https://doi.org/10.1016/j.ajem.2025.04.023>. Acesso em: 22 set. 2025.

MALL, S. et al. Implementation of machine learning techniques for disease diagnosis. Materials Today: Proceedings, Elsevier, v. 51, p. 2198-2201, 2022. Disponível em: <https://doi.org/10.1016/j.matpr.2021.11.274>. Acesso em: 22 set. 2025.

MARINHO, A. A economia das filas no sistema único de saúde (SUS) brasileiro. Brasília: Instituto de Pesquisa Econômica Aplicada (IPEA), 2009. (Texto para Discussão, n. 1390). Disponível em: <https://www.econstor.eu/bitstream/10419/91329/1/604938802.pdf>. Acesso em: 22 set. 2025.

MCKINNEY, W. pandas: a foundational Python library for data analysis and modeling. Journal of Open Source Software, The Open Journal, v. 5, n. 51, p. 2464, jul. 2020. Disponível em: <https://doi.org/10.21105/joss.02646>. Acesso em: 22 set. 2025.

PAIXÃO, G. M. M. et al. Machine Learning na Medicina: Revisão e Aplicabilidade. Arquivos Brasileiros de Cardiologia, Sociedade Brasileira de Cardiologia, v. 118, n. 1, p. 95-102, jan. 2022. Disponível em: <https://doi.org/10.36660/abc.20200596>. Acesso em: 22 set. 2025.

PARENTI, N. et al. A systematic review on the validity and reliability of an emergency department triage scale, the Manchester Triage System. International Journal of Nursing

Studies, Elsevier, v. 51, n. 7, p. 1062-1069, jul. 2014. Disponível em: <https://doi.org/10.1016/j.ijnurstu.2014.01.013>. Acesso em: 22 set. 2025.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, Microtome Publishing, v. 12, p. 2825-2830, 2011. Disponível em: <http://www.jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 22 set. 2025.

RANA, M.; BHUSHAN, M. Machine learning and deep learning approach for medical image analysis: diagnosis to detection. Multimedia Tools and Applications, Springer, v. 82, p. 26731-26769, dez. 2022. Disponível em: <https://doi.org/10.1007/s11042-022-14305-w>. Acesso em: 22 set. 2025.

SIIRA, E.; JOHANSSON, H.; NYGREN, J. Mapping and Summarizing the Research on AI Systems for Automating Medical History Taking and Triage: Scoping Review. Journal of Medical Internet Research, v. 27, p. e53741, 2025. Disponível em: <https://doi.org/10.2196/53741>. Acesso em: 22 set. 2025.